



## KLAS — Krinik Local Agent System

---

ENGLISH

РУССКИЙ

License

MIT

Version

1.0

Framework

KAIF

Platform

Windows 11

GPU

NVIDIA CUDA

### English

---

**KLAS is a self-hosted AI ecosystem that lives entirely on your own PC.** A local large language model runs on your gaming GPU; autonomous agents work in your editor; a web dashboard is the single control panel; an offline Wikipedia is the knowledge base; and a simple chat serves your family — all without sending a byte to the cloud. It sleeps until called, runs stably, and gets as close to the feel of Claude AI as a single graphics card allows.

The cat is KOT KRINIK himself. He approves.

**Universal by design.** One guided wizard takes anyone — even a first-timer — from `git clone` to a living AI on their machine: it detects your hardware, asks a few questions, downloads everything, sets up desktop shortcuts, and brings the stack up. One local AI then serves three audiences at once — the

owner (an agent in the editor + a remote API), close ones (a private chat), and knowledge (offline Wikipedia, searchable from the chat).

### Why

- **Privacy** — your data never leaves the machine; the cloud is optional.
- **Offline** — the LLM, the agents, and the knowledge base all work without the internet.
- **Your own server** — it sleeps until called and doesn't eat resources while idle.
- **Priorities**, in order: **stability** → **intelligence** → **speed**. Context-overflow crashes are unacceptable on principle.
- **Minimum moving parts** — ideally one engine and one model; borrow proven open-source, don't reinvent.

### What is inside

| Component        | Implementation                                                                                                 | Role                                                    |
|------------------|----------------------------------------------------------------------------------------------------------------|---------------------------------------------------------|
| Inference engine | <a href="#">llama.cpp</a> ( <code>llama-server</code> , CUDA)                                                  | the LLM on your GPU                                     |
| Model manager    | <a href="#">llama-swap</a> — "sleeps until called"                                                             | auto load/unload on demand; web UI at <code>/ui/</code> |
| Main model       | <b>Qwythos-9B</b> (Q5_K_M) — <b>256K context</b>                                                               | the brain (agent-bench 6/6, needle @148K )              |
| Alt models       | Qwen3.5-35B-A3B (MoE, 98K), Ornith-1.0-35B (SWE-bench 75.6), Qwen3.6-27B (64K), Gemma-4-12B (131K, multimodal) | swapped by name                                         |
| Agent frontend   | Zoo Code (VS Code) — local & remote                                                                            | the agent in your editor                                |
| Family chat      | <a href="#">Open WebUI</a> — personal accounts, private chats                                                  | a simple ChatGPT-like chat for close ones               |
| Knowledge base   | kiwix (offline Wikipedia + more <code>.zim</code> ) with search from chat & from the agent (MCP)               | offline knowledge for people and agents                 |
| Control panel    | homepage + Caddy                                                                                               | one entry point: dashboard, model UI, wiki, remote API  |
| Remote access    | Caddy + Tailscale Funnel                                                                                       | OpenAI-compatible API + web over the internet           |

| Component | Implementation                                                   | Role                                    |
|-----------|------------------------------------------------------------------|-----------------------------------------|
| Lifecycle | tray controller + desktop shortcuts (Run / Stop / Control Panel) | start/stop the whole stack in one click |

## Install

**The wizard** — multilingual (RU/EN), checks your hardware, foolproof, survives reboots:

```
git clone https://github.com/MikalaiKryvusha/KLAS.git F:\KLAS
node F:\KLAS\tools\install.mjs
```

It picks a language, detects your GPU / driver / Docker / disk, lets you choose models and knowledge bases from the **live Kiwix catalog** (title, size, article count), downloads everything, creates desktop shortcuts, and brings the stack up. Stop and re-run anytime — it continues where it left off. `--yes` installs with recommended defaults, no questions.

**Or the low-level engine** (same downloads, no wizard), and an **anonymous** de-identified copy:

```
node F:\KLAS\tools\deploy.mjs --apply # deploy by manifest (idempotent)
node F:\KLAS\tools\anonymize.mjs --apply --reinit-git # a copy with no author/origin
```

Requirements: Windows 11, NVIDIA GPU (16 GB VRAM recommended), Node  $\geq 20$ , git, winget; Docker optional (knowledge base + dashboard). Heavy artifacts (engine, models, `.zim`, docker images) are **not** in the repository — they are pulled at install time.

## Using it

- **Control panel** — `http://localhost/` locally (no password), or `https://<your-machine>.ts.net/` over the internet (behind login). Widgets link to the model UI, the wiki, and remote services.
- **Chat for close ones** — Open WebUI, with personal accounts and private chats; the model can search the local Wikipedia via a built-in Kiwix tool.
- **Remote API** (Zoo Code / any OpenAI client): Base URL `https://<your-machine>.ts.net/llm/v1`, Bearer key from `caddy/PASSWORD.local.txt`, model `qwytos-9b` (or an alt by name).

## Roadmap

| Phase      | What                                                      | Status |
|------------|-----------------------------------------------------------|--------|
| Foundation | KAIF, environment audit, birth of KLAS (name, home, logo) |        |

| Phase                     | What                                                      | Status |
|---------------------------|-----------------------------------------------------------|--------|
| Stable stack              | inference without context-overflow crashes                |        |
| Optimal stack             | model research + local benchmarks                         |        |
| Sleeps until called       | llama-swap lifecycle + tray control                       |        |
| Control panel & knowledge | dashboard, offline wiki, search from chat & agent         |        |
| Universal deploy          | smart multilingual installer-wizard, turnkey              |        |
| Daily driver              | everyday use, access for close ones                       |        |
| Jarvis                    | humanlike voice assistant, screen vision, Windows control |        |

### Managed by KAIF

Development runs as a human-visionary + AI-agent tandem on the **KAIF** framework. **KLAS ≠ KAIF**: KAIF is an auxiliary dev framework deployed locally to help build KLAS — for KLAS it is a 3rd-party tool and is **not** vendored into this repository.

### Русский

**KLAS — self-hosted экосистема агентского ИИ, целиком живущая на вашем личном ПК.**

Локальная LLM работает на геймерской видеокарте; автономные агенты — в редакторе; веб-дашборд — единый пульт; оффлайн-Википедия — база знаний; а простой чат служит родным — и всё это без единого байта в облако. Система «спит», пока не позвали, работает стабильно и максимально приближается к ощущению Claude AI в пределах одной видеокарты.

Кот — это Кот Криник собственной персоной. Одобряет.

**Универсальность в основе.** Один мастер проводит любого — даже новичка — от `git clone` до живого ИИ на его машине: определяет железо, задаёт пару вопросов, всё скачивает, создаёт ярлыки на Рабочем столе и поднимает стек. Один локальный ИИ обслуживает сразу троих: владельца (агент в редакторе + удалённый API), близких (приватный чат) и знания (оффлайн-Википедия с поиском прямо из чата).

### Зачем

- **Приватность** — данные не покидают машину; облако не обязательно.
- **Оффлайн** — LLM, агенты и база знаний работают без интернета.

- **Свой сервер** — «спит», пока не позвали, не ест ресурсы в простое.
- **Приоритеты** по порядку: **стабильность** → **ум** → **скорость**. Ошибки переполнения контекста недопустимы в принципе.
- **Минимум сущностей** — в идеале один движок и одна модель; берём проверенный open-source, а не изобретаем заново.

### Что внутри

| Компонент          | Реализация                                                                                                          | Роль                                                             |
|--------------------|---------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------|
| Движок инференса   | <a href="#">llama.cpp</a> ( llama-server , CUDA)                                                                    | LLM на вашей GPU                                                 |
| Менеджер моделей   | <a href="#">llama-swap</a> — «спит, пока не позовут»                                                                | автозагрузка/выгрузка по запросу; веб-UI на <a href="#">/ui/</a> |
| Основная модель    | <b>Qwythos-9B</b> (Q5_K_M) — <b>256K контекста</b>                                                                  | «мозг» (agent-bench 6/6, needle @148K )                          |
| Запасные модели    | Qwen3.5-35B-A3B (MoE, 98K), Ornith-1.0-35B (SWE-bench 75.6), Qwen3.6-27B (64K), Gemma-4-12B (131K, мультимодальная) | свопятся по имени                                                |
| Агентский фронтенд | Zoo Code (VS Code) — локально и удалённо                                                                            | агент в редакторе                                                |
| Чат для родных     | <a href="#">Open WebUI</a> — личные аккаунты, приватные чаты                                                        | простой ChatGPT-подобный чат близким                             |
| База знаний        | kiwix (оффлайн-Википедия и другие <a href="#">.zim</a> ) с поиском из чата и от агента (MCP)                        | оффлайн-знания людям и агентам                                   |
| Пульт управления   | homepage + Caddy                                                                                                    | единый вход: дашборд, UI моделей, вики, удалённый API            |
| Удалённый доступ   | Caddy + Tailscale Funnel                                                                                            | OpenAI-совместимый API + веб через интернет                      |
| Жизненный цикл     | трей-контроллер + ярлыки (Run / Stop / Control Panel)                                                               | запуск/остановка всего стека в один клик                         |

### Установка

**Мастер** — мультиязычный (рус/eng), проверяет железо, с защитой от дурака, переживает перезагрузки:

```
git clone https://github.com/MikalaiKryvusha/KLAS.git F:\KLAS
node F:\KLAS\tools\install.mjs
```

Он выбирает язык, определяет GPU / драйвер / Docker / диск, даёт выбрать модели и базы знаний из **живого каталога Kiwix** (название, размер, число статей), всё скачивает, создаёт ярлыки на Рабочем столе и поднимает стек. Можно прервать и запустить снова — продолжит с места остановки. Флаг `--yes` ставит с рекомендуемыми настройками, без вопросов.

**Или низкоуровневый движок** (те же скачивания, без мастера) и **анонимная** обезличенная копия:

```
node F:\KLAS\tools\deploy.mjs --apply # развёртывание по манифесту (идемпотентно)
node F:\KLAS\tools\anonymize.mjs --apply --reinit-git # копия без автора/origin
```

Требования: Windows 11, NVIDIA GPU (16 ГБ VRAM рекоменд.), Node  $\geq 20$ , git, winget; Docker — опционально (база знаний + дашборд). Тяжёлое (движок, модели, `.zim`, docker-образы) в репозиторий **не** входит — докачивается при установке.

## Как пользоваться

- **Пульт управления** — `http://localhost/` локально (без пароля) или `https://<ваша-машина>.ts.net/` через интернет (под логином). Виджеты ведут на UI моделей, вики и удалённые сервисы.
- **Чат для родных** — Open WebUI: личные аккаунты и приватные чаты; модель умеет искать по локальной Википедии встроенным инструментом Kiwix.
- **Удалённый API** (Zoo Code / любой OpenAI-клиент): Base URL `https://<ваша-машина>.ts.net/11m/v1`, Bearer-ключ из `caddy/PASSWORD.local.txt`, модель `qwythos-9b` (или запасная по имени).

## Дорожная карта

| Фаза                    | Что                                                      | Статус |
|-------------------------|----------------------------------------------------------|--------|
| Фундамент               | KAIF, аудит окружения, рождение KLAS (имя, дом, логотип) |        |
| Стабильный стек         | инференс без падений от переполнения контекста           |        |
| Оптимальный стек        | исследование моделей + локальные бенчи                   |        |
| «Спит, пока не позовут» | жизненный цикл llama-swap + трей-управление              |        |
| Пульт и знания          | дашборд, оффлайн-вики, поиск из чата и от агента         |        |

| Фаза                        | Что                                                                     | Статус |
|-----------------------------|-------------------------------------------------------------------------|--------|
| Универсальное развёртывание | умный мультиязычный мастер-установщик под ключ                          |        |
| Ежедневная работа           | повседневное использование, доступ близким                              |        |
| Jarvis                      | человекоподобный голосовой ассистент, зрение экрана, управление Windows |        |

## Управляется через KAIF

Разработкой рулит тандем «человек-визионер + ИИ-агент» на фреймворке [KAIF](#). **KLAS ≠ KAIF**: KAIF — вспомогательный dev-фреймворк, развёрнутый локально в помощь разработке KLAS; для KLAS он 3rd-party-инструмент и в этот репозиторий **не** упаковывается.

---

## Author · Автор

2026 **Mikalai Kryvusha** aka **KOT KRINIK** · Николай Кривуша aka Кот Криник

License · Лицензия — [MIT](#).