



KLAS — Krinik Local Agent System

ENGLISH

РУССКИЙ

License

MIT

Version

0.2

Framework

KAIF

Platform

Windows 11

GPU

RTX 5070 Ti 16 GB

English · Русский

KLAS — a self-hosted AI ecosystem on your own PC: a local LLM on a gaming GPU, autonomous agents, a web control dashboard, and an offline knowledge base (local Wikipedia). Total data privacy, offline efficiency, and an experience as close to Claude AI as a single RTX 5070 Ti 16 GB allows. It sleeps until called, runs stably, and serves its owner and their close ones.

The cat on the banner is KOT KRINIK himself. He approves.

Deploy on a fresh PC in **two commands** — clone, then one deploy that pulls the heavy parts (engine, models, docker images) by itself. The repository is the frame; nothing heavy is vendored.

Why

- **Privacy** — your data never leaves the machine; the cloud is optional.
- **Offline** — the LLM, agents, and knowledge base work without the internet.
- **Your own server** — sleeps until called, doesn't eat resources while idle.
- **Priorities** (in this order): **stability** → **intelligence** → **speed**. Context-overflow errors are unacceptable on principle.

What is inside

Component	Current implementation	Role
Inference engine	llama.cpp (llama-server , CUDA)	LLM on the GPU
Model manager	llama-swap — "sleeps until called"	auto load/unload by request, web UI at /ui/
Main model	Qwythos-9B (Q5_K_M) — 256K context	the "brain" (agent-bench 6/6, needle @148K)
Alt models	Qwen3.5-35B-A3B (smart MoE, 98K), Ornith-1.0-35B (SWE-bench 75.6), Qwen3.6-27B (64K), gemma-4-12b (131K, multimodal)	swapped by name
Agent frontend	Zoo Code (VS Code) — local & remote	the agent in the editor
Knowledge base	kiwix (local Wikipedia) + openzim-mcp search for the agent	offline knowledge for people & agents
Control panel	homepage (docker) + llama-swap UI	single entry point (Phase 5)
Dashboard	homepage (docker) + llama-swap UI	the "control panel"
Remote access	Caddy + Tailscale Funnel	OpenAI-compatible API over the internet

Deploy on a fresh PC

```
git clone https://github.com/MikalaiKryvusha/KLAS.git F:\KLAS
node F:\KLAS\tools\deploy.mjs # dry-run: prints the plan
node F:\KLAS\tools\deploy.mjs --apply # deploy (pulls models & docker images)
```

Requirements: Windows 11, NVIDIA GPU (16 GB VRAM recommended), Node ≥ 20 , git, winget; docker optional (knowledge base + dashboard). Heavy artifacts (models, `.zim`, 3rd-party modules) are **not** in the repo — they are pulled at deploy time.

Anonymous install (a de-identified copy — no author, no origin):

```
node F:\KLAS\tools\anonymize.mjs --apply --reinit-git
```

Remote access (Zoo Code from any computer)

An OpenAI-compatible endpoint over the internet — just a URL and an API key:

- **Base URL:** `https://<your-machine>.ts.net/llm/v1`
- **API Key:** a Bearer key (stored in `caddy/PASSWORD.local.txt`)
- **Model:** `qwythos-9b` (or `qwen3.5-35b` / `qwen3.6-27b` / `gemma-4-12b`)

Roadmap

Phase	What	Status
0 · 0.5	Foundation (KAIF, audit) · Birth of KLAS (name, home, logo)	
1	Stack stabilization (context-overflow bug)	
2	Optimal-stack research + local benchmarks	
4	"Sleeps until called" lifecycle (llama-swap + autostart)	
5	Control-panel dashboard + knowledge base	
6	Daily driver, access for close ones	
	Remote API access · anonymous deploy · Qwythos 256K	(0.1)
	Control panel · knowledge search for the agent (MCP) · Ornith-35B	(0.2)

Managed by KAIF

Development is run by the human-visionary + AI-agent tandem on the **KAIF** framework. **KLAS ≠ KAIF**: KAIF is an auxiliary dev framework deployed locally to help build KLAS — for KLAS it is a 3rd-party tool and is **not** vendored into this repository.

Русский · English

KLAS — self-hosted экосистема агентского ИИ на личном ПК: локальная LLM на геймерской GPU, автономные агенты, веб-дашборд управления и оффлайн-база знаний (локальная википедия). Полная приватность данных, оффлайн-эффективность и опыт, максимально близкий к Claude AI в пределах одной RTX 5070 Ti 16 GB. Система «спит», пока не позвали, работает стабильно и служит владельцу и близким.

Кот на баннере — Кот Криник собственной персоной. Одобряет.

Развёртывание на чистом ПК — **две команды**: клон и один деплой, который сам докачивает тяжёлое (движок, модели, docker-образы). Репозиторий — это каркас; ничего тяжёлого в него не упаковано.

Зачем

- **Приватность** — данные не покидают машину; облако не обязательно.
- **Оффлайн** — LLM, агенты и база знаний работают без интернета.
- **Свой сервер** — «спит», пока не позвали, не ест ресурсы в простое.
- **Приоритеты** (в этом порядке): **стабильность** → **ум** → **скорость**. Ошибки переполнения контекста недопустимы в принципе.

Что внутри

Компонент	Текущая реализация	Роль
Движок инференса	llama.cpp (llama-server , CUDA)	LLM на GPU
Менеджер моделей	llama-swap — «спит, пока не позовут»	автозагрузка/выгрузка по запросу, веб-UI на /ui/
Основная модель	Qwythos-9B (Q5_K_M) — 256K контекста	«мозг» (agent-bench 6/6, needle @148K)

Компонент	Текущая реализация	Роль
Запасные модели	Qwen3.5-35B-A3B (умный MoE, 98K), Ornith-1.0-35B (SWE-bench 75.6), Qwen3.6-27B (64K), gemma-4-12b (131K, мультимодальная)	свопятся по имени
Агентский фронтенд	Zoo Code (VS Code) — локально и удалённо	агент в редакторе
База знаний	kiwix (локальная википедия) + поиск openzim-mcp для агента	оффлайн-знания людям и агентам
Дашборд	homepage (docker) + UI llama-swap	«пульт управления» (Фаза 5)
Удалённый доступ	Caddy + Tailscale Funnel	OpenAI-совместимый API через интернет

Развернуть на новом ПК

```
git clone https://github.com/MikalaiKryvusha/KLAS.git F:\KLAS
node F:\KLAS\tools\deploy.mjs # репетиция: печатает план
node F:\KLAS\tools\deploy.mjs --apply # развёртывание (докачивает модели и docker-образы)
```

Требования: Windows 11, NVIDIA GPU (16 ГБ VRAM рекоменд.), Node ≥20, git, winget; docker — опционально (база знаний + дашборд). Тяжёлое (модели, `.zim`, сторонние модули) в репозиторий **не** входит — докачивается при развёртывании.

Анонимная установка (обезличенная копия — без автора и origin):

```
node F:\KLAS\tools\anonymize.mjs --apply --reinit-git
```

Удалённый доступ (Zoo Code с любого компьютера)

OpenAI-совместимая точка входа через интернет — достаточно URL и API-ключа:

- **Base URL:** `https://<ваша-машина>.ts.net/llm/v1`
- **API Key:** Bearer-ключ (хранится в `caddy/PASSWORD.local.txt`)
- **Модель:** `qwythos-9b` (или `qwen3.5-35b` / `qwen3.6-27b` / `gemma-4-12b`)

Дорожная карта

Фаза	Что	Статус
0 · 0.5	Фундамент (KAIF, аудит) · Рождение KLAS (имя, дом, логотип)	
1	Стабилизация стека (баг переполнения контекста)	
2	Исследование оптимального стека + локальные бенчи	
4	Жизненный цикл «спит, пока не позовут» (llama-swap + автостарт)	
5	Веб-дашборд «пульт» + база знаний	
6	Ежедневная работа, доступ близким	
	Удалённый API-доступ · анонимный деплой · Qwythos 256K	(0.1)
	Пульт управления · поиск по базе знаний для агента (MCP) · Ornith-35B	(0.2)

Управляется через KAIF

Разработкой рулит тандем «человек-визионер + ИИ-агент» на фреймворке **KAIF**. **KLAS ≠ KAIF**: KAIF — вспомогательный dev-фреймворк, развёрнутый локально в помощь разработке KLAS; для KLAS он 3rd-party-инструмент и в этот репозиторий **не** упаковывается.

Author · Автор

2026 **Mikalai Kryvusha** aka **KOT KRINIK** · Николай Кривуша aka Кот Криник

License · Лицензия — [MIT](#).