



KLAS — Krinik Local Agent System

ENGLISH

РУССКИЙ

License

MIT

Version

1.0

Framework

KAIF

Platform

Windows 11

GPU

NVIDIA CUDA

English

English • [Русский](#)

KLAS is a self-hosted AI ecosystem that lives entirely on your own PC. A local large language model runs on your gaming GPU; autonomous agents work in your editor; a web dashboard is the single control panel; an offline Wikipedia is the knowledge base; and a simple chat serves your family — all without sending a byte to the cloud. It sleeps until called, runs stably, and gets as close to the feel of Claude AI as a single graphics card allows.

The cat is KOT KRINIK himself. He approves.

Universal by design. One guided wizard takes anyone — even a first-timer — from `git clone` to a living AI on their machine: it detects your hardware, asks a few questions, downloads everything, sets up desktop shortcuts, and brings the stack up. One local AI then serves three audiences at once — the owner (an agent in the editor + a remote API), close ones (a private chat), and knowledge (offline Wikipedia, searchable from the chat).

Why

- **Privacy** — your data never leaves the machine; the cloud is optional.
- **Offline** — the LLM, the agents, and the knowledge base all work without the internet.
- **Your own server** — it sleeps until called and doesn't eat resources while idle.
- **Priorities**, in order: **stability** → **intelligence** → **speed**. Context-overflow crashes are unacceptable on principle.
- **Minimum moving parts** — ideally one engine and one model; borrow proven open-source, don't reinvent.

What is inside

Component	Implementation	Role
Inference engine	<code>llama.cpp</code> (<code>llama-server</code> , CUDA)	the LLM on your GPU
Model manager	<code>llama-swap</code> — "sleeps until called"	auto load/unload on demand; web UI at <code>/ui/</code>
Main model	Qwen3.6-35B-A3B (MoE, UD-IQ3_S, 98K context)	the brain — chosen for intelligence over speed (~164 t/s is already plenty)
Long-context specialist	Qwythos-9B (Q5_K_M) — 256K context	needle @148K — for very long documents
Alt models	Qwen3.5-35B-A3B (fallback), Ornith-1.0-35B (SWE-bench 75.6), Qwen3.6-27B (64K), Gemma-4-12B (131K, multimodal)	swapped by name
Assistant core	<code>OpenClaw</code> on the local models	the agent loop behind the assistant: skills, tool calls, sessions
Voice (in progress)	<code>Silero</code> TTS (<code>v5_ru</code> + <code>v3_en</code> , resident) + <code>GigaAM-v3</code> STT via sherpa-onnx — fully offline, on CPU	KLAS speaks and hears; switches RussianEnglish inside one reply, in one voice ; a turn takes ~8 s end to end
Agent frontend	Zoo Code (VS Code) — local & remote	the agent in your editor

Component	Implementation	Role
Family chat	Open WebUI — personal accounts, private chats	a simple ChatGPT-like chat for close ones
Knowledge base	kiwix (offline Wikipedia + more <code>.zim</code>) with search from chat & from the agent (MCP)	offline knowledge for people and agents
Control panel	homepage + Caddy	one entry point: dashboard, model UI, wiki, remote API
Remote access	Caddy + Tailscale Funnel	OpenAI-compatible API + web over the internet
Lifecycle	tray controller + desktop shortcuts (Run / Stop / Control Panel)	start/stop the whole stack in one click

Install

The wizard — multilingual (RU/EN), checks your hardware, foolproof, survives reboots:

```
git clone https://github.com/MikalaiKryvusha/KLAS.git F:\KLAS
node F:\KLAS\tools\install.mjs
```

It picks a language, detects your GPU / driver / Docker / disk, lets you choose models and knowledge bases from the **live Kiwix catalog** (title, size, article count), downloads everything, creates desktop shortcuts, and brings the stack up. Stop and re-run anytime — it continues where it left off. `--yes` installs with recommended defaults, no questions.

Or the low-level engine (same downloads, no wizard), and an **anonymous** de-identified copy:

```
node F:\KLAS\tools\deploy.mjs --apply # deploy by manifest (idempotent)
node F:\KLAS\tools\anonymize.mjs --apply --reinit-git # a copy with no author/origin
```

Requirements: Windows 11, NVIDIA GPU (16 GB VRAM recommended), Node ≥ 20 , git, winget; Docker optional (knowledge base + dashboard). Heavy artifacts (engine, models, `.zim`, docker images) are **not** in the repository — they are pulled at install time.

Using it

- **Control panel** — `http://localhost/` locally (no password), or `https://<your-machine>.ts.net/` over the internet (behind login). Widgets link to the model UI, the wiki, and remote services.

- **Chat for close ones** — Open WebUI, with personal accounts and private chats; the model can search the local Wikipedia via a built-in Kiwix tool.
- **Remote API** (Zoo Code / any OpenAI client): Base URL `https://<your-machine>.ts.net/llm/v1` , Bearer key from `caddy/PASSWORD.local.txt` , model `qwen3.6-35b-a3b` (or another by name).

Roadmap

Phase	What	Status
Foundation	KAIF, environment audit, birth of KLAS (name, home, logo)	
Stable stack	inference without context-overflow crashes	
Optimal stack	model research + local benchmarks	
Sleeps until called	llama-swap lifecycle + tray control	
Control panel & knowledge	dashboard, offline wiki, search from chat & agent	
Universal deploy	smart multilingual installer-wizard, turnkey	
Daily driver	everyday use, access for close ones	
Jarvis	humanlike voice assistant, screen vision, Windows control	

Jarvis is underway, not done: the assistant core is chosen and running on the local models, and the voice pipeline speaks, hears and holds a dialogue offline. English words are transliterated into Cyrillic so that a single voice carries the whole reply. Next up — launching by name («Джарвис», «Джой»), the persona voice clones, the Android node, voice authentication, and Windows control.

Managed by KAIF

Development runs as a human-visionary + AI-agent tandem on the **KAIF** framework (**v1.6**). **KLAS ≠ KAIF**: KAIF is an auxiliary dev framework deployed locally to help build KLAS — for KLAS it is a 3rd-party tool and is **not** vendored into this repository.

Русский

Русский • [English](#)

KLAS — self-hosted экосистема агентского ИИ, целиком живущая на вашем личном ПК.

Локальная LLM работает на геймерской видеокарте; автономные агенты — в редакторе; веб-дашборд — единый пульт; оффлайн-Википедия — база знаний; а простой чат служит родным — и

всё это без единого байта в облако. Система «спит», пока не позвали, работает стабильно и максимально приближается к ощущению Claude AI в пределах одной видеокарты.

Кот — это Кот Криник собственной персоной. Одобряет.

Универсальность в основе. Один мастер проводит любого — даже новичка — от `git clone` до живого ИИ на его машине: определяет железо, задаёт пару вопросов, всё скачивает, создаёт ярлыки на Рабочем столе и поднимает стек. Один локальный ИИ обслуживает сразу троих: владельца (агент в редакторе + удалённый API), близких (приватный чат) и знания (оффлайн-Википедия с поиском прямо из чата).

Зачем

- **Приватность** — данные не покидают машину; облако не обязательно.
- **Оффлайн** — LLM, агенты и база знаний работают без интернета.
- **Свой сервер** — «спит», пока не позвали, не ест ресурсы в простое.
- **Приоритеты** по порядку: **стабильность** → **ум** → **скорость**. Ошибки переполнения контекста недопустимы в принципе.
- **Минимум сущностей** — в идеале один движок и одна модель; берём проверенный open-source, а не изобретаем заново.

Что внутри

Компонент	Реализация	Роль
Движок инференса	<code>llama.cpp</code> (<code>llama-server</code> , CUDA)	LLM на вашей GPU
Менеджер моделей	<code>llama-swap</code> — «спит, пока не позовут»	автозагрузка/выгрузка по запросу; веб-UI на <code>/ui/</code>
Основная модель	Qwen3.6-35B-A3B (MoE, UD-IQ3_S, 98K контекста)	«мозг» — выбрана за УМ, а не за скорость (~164 t/s уже за глаза)
Спец по длинному контексту	Qwythos-9B (Q5_K_M) — 256K контекста	needle @148K — для очень длинных документов

Компонент	Реализация	Роль
Запасные модели	Qwen3.5-35B-A3B (fallback), Ornith-1.0-35B (SWE-bench 75.6), Qwen3.6-27B (64K), Gemma-4-12B (131K, мультимодальная)	своются по имени
Ядро ассистента	OpenClaw на локальных моделях	агентный цикл ассистента: навыки, тул-коллы, сессии
Голос (в работе)	Silero TTS (резидентный) + Giga AM-v3 STT через sherpa-onnx — полностью офлайн, на CPU	KLAS говорит и слышит; ход занимает ~8 с от вопроса до ответа. Английские слова произносятся транслитерацией кириллицей — чтобы диктор оставался ОДИН на всю реплику (две модели давали смену голоса посреди фразы). Клоны персон Jarvis/Joi — в подборе
Агентский фронтенд	Zoo Code (VS Code) — локально и удалённо	агент в редакторе
Чат для родных	Open WebUI — личные аккаунты, приватные чаты	простой ChatGPT-подобный чат близким
База знаний	kiwix (офлайн-Википедия и другие <code>.zim</code>) с поиском из чата и от агента (MCP)	офлайн-знания людям и агентам
Пульт управления	homepage + Caddy	единый вход: дашборд, UI моделей, вики, удалённый API
Удалённый доступ	Caddy + Tailscale Funnel	OpenAI-совместимый API + веб через интернет
Жизненный цикл	трей-контроллер + ярлыки (Run / Stop / Control Panel)	запуск/остановка всего стека в один клик

Установка

Мастер — мультиязычный (рус/eng), проверяет железо, с защитой от дурака, переживает перезагрузки:

```
git clone https://github.com/MikalaiKryvusha/KLAS.git F:\KLAS
node F:\KLAS\tools\install.mjs
```

Он выбирает язык, определяет GPU / драйвер / Docker / диск, даёт выбрать модели и базы знаний из **живого каталога Kiwix** (название, размер, число статей), всё скачивает, создаёт ярлыки на Рабочем столе и поднимает стек. Можно прервать и запустить снова — продолжит с места остановки. Флаг `--yes` ставит с рекомендуемыми настройками, без вопросов.

Или низкоуровневый движок (те же скачивания, без мастера) и **анонимная** обезличенная копия:

```
node F:\KLAS\tools\deploy.mjs --apply # развёртывание по манифесту (идемпотентно)
node F:\KLAS\tools\anonymize.mjs --apply --reinit-git # копия без автора/origin
```

Требования: Windows 11, NVIDIA GPU (16 ГБ VRAM рекоменд.), Node ≥20, git, winget; Docker — опционально (база знаний + дашборд). Тяжёлое (движок, модели, `.zim`, docker-образы) в репозиторий **не** входит — докачивается при установке.

Как пользоваться

- **Пульт управления** — `http://localhost/` локально (без пароля) или `https://<ваша-машина>.ts.net/` через интернет (под логином). Виджеты ведут на UI моделей, вики и удалённые сервисы.
- **Чат для родных** — Open WebUI: личные аккаунты и приватные чаты; модель умеет искать по локальной Википедии встроенным инструментом Kiwix.
- **Удалённый API** (Zoo Code / любой OpenAI-клиент): Base URL `https://<ваша-машина>.ts.net/llm/v1`, Bearer-ключ из `caddy/PASSWORD.local.txt`, модель `qwen3.6-35b-a3b` (или другая по имени).

Дорожная карта

Фаза	Что	Статус
Фундамент	KAIF, аудит окружения, рождение KLAS (имя, дом, логотип)	
Стабильный стек	инференс без падений от переполнения контекста	
Оптимальный стек	исследование моделей + локальные бенчи	
«Спит, пока не позовут»	жизненный цикл llama-swap + трей-управление	
Пульт и знания	дашборд, оффлайн-вики, поиск из чата и от агента	
Универсальное развёртывание	умный мультязычный мастер-установщик под ключ	
Ежедневная работа	повседневное использование, доступ близким	

Фаза	Что	Статус
Jarvis	человекоподобный голосовой ассистент, зрение экрана, управление Windows	

Jarvis в работе, а не готов: ядро ассистента выбрано и запущено на локальных моделях, голосовой тракт говорит, слышит и держит диалог офлайн. Английские слова произносятся транслитерацией кириллицей — чтобы всю реплику вёл ОДИН голос. Впереди — запуск по имени («Джарвис», «Джой»), голоса персон, Android-нода, голосовая аутентификация и управление Windows.

Управляется через KAIF

Разработкой рулит тандем «человек-визионер + ИИ-агент» на фреймворке **KAIF (v1.6)**. **KLAS** ≠ **KAIF**: KAIF — вспомогательный dev-фреймворк, развёрнутый локально в помощь разработке KLAS; для KLAS он 3rd-party-инструмент и в этот репозиторий **не** упаковывается.

Author · Автор

2026 **Mikalai Kryvusha** aka **KOT KRINIK** · Николай Кривуша aka Кот Криник

License · Лицензия — [MIT](#).